

武汉大学

本科毕业论文（设计）

面向星地协同在轨处理的
任务调度方法

姓 名：杨博丞
学 号：2021301051263
专 业：计算机科学与技术
学 院：计算机学院
指导教师：李清安


二〇二五年四月

原创性声明

本人郑重声明：所呈交的论文(设计)，是本人在指导教师的指导下，严格按照学校和学院有关规定完成的。除文中已经标明引用的内容外，本论文(设计)不包含任何其他个人或集体已发表及撰写的研究成果。对本论文(设计)做出贡献的个人和集体，均已在文中以明确方式标明。本人承诺在论文(设计)工作过程中没有伪造数据等行为。若在本论文(设计)中有侵犯任何方面知识产权的行为，由本人承担相应的法律责任。

作者签名：杨博丞 指导教师签名：

日期：2025 年 5 月 14 日




版权使用授权书

本人完全了解武汉大学有权保留并向有关部门或机构送交本论文(设计)的复印件和电子版，允许本论文(设计)被查阅和借阅。本人授权武汉大学将本论文的全部或部分内容编入有关数据进行检索和传播，可以采用影印、缩印或扫描等复制手段保存和汇编本论文(设计)。

作者签名：杨博丞 指导教师签名：

日期：2025 年 5 月 14 日



摘要

随着卫星数据采集能力的迅猛发展,短小时内获取的海量信息给卫星数据处理能力以及卫星计算任务调度能力都带了不小的挑战。由于太空环境的特殊性,卫星自搭载的板卡并不具有处理对算力需求极大的任务的能力。其一是卫星上极端有限的计算资源,其二是星载板卡需要进行功耗控制以及发热控制,这使得难以在卫星板卡上运行现有的巨量参数遥感大模型,只能将遥感大模型部署在地面。又由于遥感小模型所需算力较少,功耗较小,所以将遥感小模型部署在卫星上,并通过地空数据传输来将需要大算力的任务发回地面处理,而将小算力任务放在卫星板卡上处理。

本文主要讨论卫星场景下的计算任务的调度问题。将对卫星进行计算任务处理的不同策略的成本进行抽象建模,并利用建立的模型构造奖励函数,通过强化学习的方法使得卫星可以根据任务特性,合理地将任务分配给地面大模型和星载小模型。这样可以最大程度的节约成本,同时高效完成计算任务,完成遥感大小模型的高效协同工作。完成的主要研究工作总结如下:

一、提出了一种卫星计算任务处理的成本建模方式。模型主要考虑了发热成本、时延成本、功耗成本、任务共置成本等卫星计算最关注的成本。模型的提出使得能够针对不同种类任务量化卫星计算的各类成本,从而合理的将不同种类任务分配给地面或卫星。

二、使用 DQN(Deep Q-Network)方法求解所提出的量化成本建模。方法依托第一条中提到的成本建模构造奖励函数,不同的任务分配策略作为动作空间,而不同的任务类型的成本参数(发热、功耗、时延等)作为状态空间训练神经网络,从而能够在接到一个新任务时快速判断最优的任务调度策略。

三、提出了 DQN-RSF(Deep Q-Network with epsilon Reset, Selective update and Flushing replay buffer)算法,其在 DQN 算法的基础上对其训练过程进行了改进,提出了 epsilon 重置、选择性的更新网络参数以及经验回放缓存重置机制,经过实验证明,DQN-RSF 算法在卫星计算任务调度场景下的性能优于 DQN 算法。

关键词: 卫星计算; 遥感大小模型; 任务调度; 成本建模; 强化学习

ABSTRACT

With the rapid development of satellite data acquisition capabilities, the massive information obtained within a short time poses significant challenges to both satellite data processing capacity and satellite computing task scheduling. Due to the uniqueness of space environment, the onboard boards of satellites are not capable of handling tasks that require high computational power. This is primarily due to two reasons: first, the extremely limited computational resources on satellites; second, the need for power consumption control and heat management for onboard boards, which makes it difficult to run existing large remote sensing models with enormous parameters on satellite boards. As a result, these models are deployed on the ground instead. On the other hand, since remote sensing small models require less computing power and consume less energy, they can be deployed on satellites. Meanwhile, tasks requiring high computational power are transmitted back to the ground for processing, while low-computational tasks are handled by satellite boards.

This paper primarily discusses the scheduling problem of computing tasks in satellite scenarios. It abstracts and models the costs associated with different strategies for handling computing tasks on satellites, constructs a reward function based on the established model, and employs reinforcement learning to enable satellites to allocate tasks appropriately between ground-based large models and onboard small models according to task characteristics. This approach aims to maximize cost efficiency while efficiently completing computing tasks. The main research achievements summarized in this paper are as follows:

1. We propose a cost modeling method for satellite computing tasks. The model primarily considers heat-related costs, latency costs, power consumption costs, and colocation costs—key factors of interest in satellite computing. The introduction of this model enables the quantification of various costs associated with different types of tasks in satellite computing, thereby allowing for reasonable allocation of tasks to ground-based or onboard resources.

2. We use the DQN method to solve the proposed quantitative cost modeling. The method is based on the cost modeling mentioned in the first point to construct a reward function, with different task allocation strategies serving as the action space and various cost parameters of task types (such as heat generation, power consumption, and latency) acting as

the state space. This allows us to train the neural network and enable quick determination of an optimal task scheduling strategy when a new task is received.

3. We propose the DQN-RSF algorithm, which improves the training process of the original DQN algorithm by incorporating epsilon resetting, selective updating of network parameters, and experience replay buffer resetting mechanisms. Experimental results demonstrate that the DQN-RSF algorithm outperforms the standard DQN algorithm in satellite computing task scheduling scenarios.

Keywords: Satellite Computing; Remote Sensing Large and Small Models; scheduling problem of computing tasks; Cost Modeling; Reinforcement Learning

目 录

摘 要	I
ABSTRACT.....	II
1 绪论	1
1.1 课题背景	1
1.2 研究意义	2
1.3 卫星在轨计算任务调度研究现状	3
1.3.1 国外研究现状	3
1.3.2 国内研究现状	4
1.4 卫星在轨计算成本量化模型研究现状	5
1.4.1 资源需求分析	5
1.4.2 必要性分析	6
1.5 技术问题	6
1.6 主要研究内容	7
2 卫星计算任务处理的量化成本数学建模	9
2.1 动机与研究思路	9
2.2 本文中大小模型的定义	10
2.3 数学模型构建	10
2.3.1 发热成本因素分析	10
2.3.2 计算量成本因素分析	11
2.3.3 时间成本因素分析	12
2.3.4 共置成本因素分析	13
2.3.5 带宽成本因素分析	13
2.4 动作空间中的成本建模	14
2.4.1 卫星侧的成本建模	15
2.4.2 地面侧的成本建模	15
2.4.3 星地双侧协同成本建模	15
2.5 本章小结	16
3 基于强化学习的任务调度网络设计	17

3.1 动机与研究思路	17
3.2 理论基础	17
3.2.1 强化学习	17
3.2.2 深度 Q 网络(Deep Q-Network, DQN)	18
3.2.3 Epsilon-Greedy 方法	19
3.3 网络的状态空间、动作空间和奖励函数设计	20
3.3.1 状态空间	20
3.3.2 动作空间	21
3.3.3 奖励函数	21
3.4 网络训练算法设计	22
3.5 神经网络结构设计	22
3.6 本章小结	23
4 基于 DQN-RSF 的卫星计算任务调度方法研究	24
4.1 动机与研究思路	24
4.2 DQN-RSF 方法	25
4.2.1 epsilon 重置(epsilon reset)	25
4.2.2 有选择地更新网络参数(selective update)	26
4.2.3 清空经验回放缓存(flushing replay buffer)	27
4.3 DQN-RSF 实现过程	28
4.4 本章小结	30
5 实验研究	31
5.1 实验环境	31
5.2 各类参数设置	31
5.2.1 量化成本建模中各项无量纲系数以及权重设置	31
5.2.2 共置成本函数设置	33
5.3 训练数据以及测试集的生成	33
5.3.1 训练数据的生成	33
5.3.2 测试数据的生成	34
5.4 实验结果分析	34

5.4.1 DQN 算法准确度分析	34
5.4.2 DQN-RSF 算法准确度分析	35
5.4.3 准确度对比分析	36
5.4.4 节省成本的对比分析	37
5.5 本章小结	38
6 结论	40
参考文献	41
致 谢	45

1 绪论

1.1 课题背景

随着太空探索活动的不断扩展，卫星系统的复杂性和任务多样性也在不断增加。现代卫星不仅需要执行传统的通信和导航任务，还承担着科学探测、遥感监测等多样化的任务。为了提高卫星系统的效率和应对复杂的任务需求，如何有效地调度在轨计算任务成为了一个关键的研究课题^[1]。

近些年来，由于深度学习算法的快速发展，基于深度学习的图像分割技术在遥感影像分析中表现出色^[2]，能够更快速地识别不同类型的地面目标；目标检测与跟踪算法(如YOLO^[3]和Faster R-CNN^[4])在速度和精度上均有显著提升，广泛应用于遥感影像解译；图像超分辨率重建和修复技术(如SRCNN^[5]和ESRGAN^[6])能够有效提升低质量图像的清晰度，被用于遥感影像超分；基于生成对抗网络(GANs^[7])的图像生成与编辑技术(如StyleGAN^[8])在遥感领域生成逼真图像方面取得了突破。这些技术的进步不仅提升了图像处理的效果和效率，也为遥感行业带来了革命性的变化，推动了智能化的发展。

随着深度学习算法的井喷式发展，其在遥感领域的应用取得了很好的效果。例如遥感图像的分割、目标识别等领域均有深度学习算法的广泛应用^[9]。但由于太空环境的特殊性，我们无法将能够部署在地面上的大型服务器或集群部署在卫星上^[10]。卫星上只能够运行算力较小、功耗较低的板卡(如NVIDIA Jetson TX2 卫星在轨计算板卡)，其算力一般只有常用于训练网络的GPU的数百分之一，功耗只有数十瓦。因此我们无法将遥感大模型直接部署在卫星上，只有地面的算力才满足遥感大模型的要求。部署在卫星板卡上的模型都是一些参数量小、需要算力小，功能专一的模型，即遥感小模型，如图1.1所示^①。这就对卫星的任务调度能力提出了较高的要求：为了节省卫星宝贵的能源、降低卫星运行时处理任务的发热^[11]、同时保证计算任务能够及时完成，需要一个能够帮助卫星决策的任务调度算法，来确定任务应该放在卫星本地计算还是交由地面计算。

^① 此处的遥感大模型指参数量较大，运行时所需要的算力较高的模型，遥感小模型则反之。




图1.1 遥感大小模型在星地上的部署示意图

因此，本文提出一种基于强化学习(Reinforcement Learning)算法^[12]的优化方案。其将卫星计算与天地通信中的各种制约因素抽象为各类成本，进而构造出奖励函数，经过训练得到一个可以帮助卫星做出有效任务调度决策的模型，帮助卫星削减运行过程中的成本、节约计算资源，同时保证任务的顺利完成。

1.2 研究意义

提出一个量化的卫星计算成本分析模型并利用其进行任务调度决策具有深远的理论、实践两方面的意义。首先，量化模型能够为卫星系统的资源分配提供精确的成本评估依据，从而在任务调度中实现资源的最优配置，避免资源浪费和超负荷运行，显著降低运营成本；同时，通过量化模型对各卫星节点的成本和性能进行全面分析，可以制定更加科学合理的任务分配策略，在满足任务需求的前提下最大化系统效率。此外，量化模型能够帮助识别哪些卫星在当前负载下运行效率最高，并确保计算任务能够被及时、高效地处理，特别是在需要实时响应的任务中，优化的调度决策能显著提升系统的整体响应速度和处理能力。

其次，利用强化学习进行任务调度决策能够实时动态地优化任务分配策略，适应卫星系统的复杂性和不确定性。强化学习算法通过不断试错和优化，能够在

复杂的任务环境中找到最优或近似最优的调度方案，从而显著提高系统的整体性能和可靠性。此外，强化学习还能够增强系统的容错能力，在面对突发事件或紧急任务时迅速生成最优的任务调度方案，确保资源的高效利用和任务的及时完成。这种动态优化的能力不仅提升了系统的灵活性和适应性，还为未来的扩展性和技术创新奠定了坚实的基础。

量化模型与强化学习的结合还能推动卫星计算系统向智能化、自动化方向发展，为实现更低的成本、更高的效率以及更优质的服务效果提供了有力支持。通过优化任务调度策略，可以在有限的卫星资源下实现更高的计算效率和服务质量，从而提高系统的投资回报率；同时，量化模型为评估不同调度策略的效果提供了客观指标，帮助企业做出更经济合理的决策。此外，这种智能化的任务调度方式还能够平衡不同用户的任务请求，确保服务质量的一致性和稳定性，提升整体用户体验。

综上所述，提出一个量化的卫星计算成本分析模型并利用强化学习进行任务调度决策不仅能够显著提升卫星系统的效率和可靠性，还能降低成本、增强容错能力，并为未来的扩展和技术进步奠定基础。这种结合推动了卫星计算系统向更高水平的发展，符合全球对智能化、自动化和可持续发展的需求，具有重要的现实意义和长远价值。

1.3 卫星在轨计算任务调度研究现状

尽管国内外在卫星任务调度方面取得了显著进展，但仍面临能源与计算资源限制：在轨计算能力受限，如何高效利用有限的资源完成多样化任务是一个持续的技术难题^[13]。

1.3.1 国外研究现状

近几年来国外卫星在轨计算任务调度的研究相对国内而言较少。来自罗马大学研究团队的Emiliano Casalicchio等人专注于任务调度问题，提出了一种系统模型，该模型考虑了卫星边缘计算环境的动力学特性，并将调度问题表述为一个优化问题。此优化问题旨在资源可用性和任务完成截止日期的约束下，最小化平均任务响应时间。并通过仿真实验验证了所提去中心化算法在所有考虑场景中的

优势：其性能优于基线集中式和分散式解决方案，且更具可扩展性和高可用性^[14]。来自韩国科学技术院的Junhong Kim等人提出了一种框架，用于调度多颗敏捷卫星的观测任务和下载任务，并考虑了实际因素，如姿态转移时间、onboard 数据容量以及立体图像获取。提出了一个混合整数线性规划(MILP)模型，以实现最优调度，该模型能够解决上述实际问题。此外，Junhong Kim等人还使用了一种基于时间窗口剪枝过程的启发式算法^[15]，用于求解所提出的 MILP 模型，并获得近似最优解。最后，通过一个全面的案例研究，验证了所提模型和启发式算法的有效性^[16]。

1.3.2 国内研究现状

国内在卫星在轨计算任务调度领域上正在飞速进步。测绘遥感信息工程国家重点实验室遥感卫星地面站沈欣课题组在遥感卫星成像任务优化调度领域提出了一种顾及在轨能源功耗的SAR卫星区域条带拼接成像任务规划方法，面向合成孔径雷达(SAR)卫星大区域拼接成像任务规划中载荷功耗约束的突出问题，构建了多条带拼接成像任务规划模型，以区域覆盖收益最大、载荷开机成像时间(成像功耗)最小为优化目标，以轨道选择编号、成像侧摆角系数、成像起止时刻为决策变量，实现轨道资源配置与成像动作序列的整体优化；针对决策变量规模大、类型多的问题，提出了一种混合局部搜索和差分进化策略的改进粒子群优化算法(LSDE-PSO)，在搜索不同阶段对两类粒子进行差分进化和局部搜索，提高了复杂模型的寻优效率^[17]。测绘遥感信息工程国家重点实验室遥感卫星地面站沈欣课题组提出了一种面向卫星多点目标成像任务调度的脉冲神经网络-前端策略优化方法，利用脉冲神经网络的时序特性捕捉任务之间的时间关联，结合PPO算法实现稳定的策略优化；通过构建任务切换时间矩阵减少姿态调整带来的资源消耗，提高任务规划的效率，利用 SNN-PPO算法的时序捕捉能力动态优化任务顺序，实现卫星在复杂观测任务条件下的全局最优^[18]。来自清华大学团队的Weisen Liu等人提出了一种面向新兴空间边缘计算(SEC)网络^[19]的能源高效任务调度框架Phoenix。制定了SEC电池能量优化(SBEO)问题，旨在最小化平均电池能耗，同时满足各种任务完成约束^[20]。来自哈尔滨工业大学团队的姜强强等人提出了一种面向异构多处理器系统(HMPS)^[21]的轨道遥感图像处理复杂任务调度模型。所提

出的模型在 makespan 和 TEC 方面分别实现了约 51% 和 54% 的成本节约。此外,采用本方法配置的 HMPS 可以获得 2.2 倍的能量效率提升,并能够处理高达 2.56×10^5 像素每瓦特(W)和每秒(s)的处理能力^[22];他们同样提出了提出了一种名为 SECORS 的资源调度技术。该技术设计了特定于遥感任务的 SEC 架构,并开发了一种端到端算法(SEC-MPH)。通过模拟实验,结果表明,与现有方法相比,SECORS 在轨道计算时间和能源消耗方面分别减少了 68.87% 和 66.60%,能源效率提升了三倍,处理能力达到每瓦特(W)和每毫秒(ms)548 像素^[23]。总而言之,国内在卫星在轨计算任务调度方面的研究较为深入,相关文献及资料也较为丰富。

1.4 卫星在轨计算成本量化模型研究现状

1.4.1 资源需求分析

在考虑遥感大小模型协同工作与调度时,全面考虑发热、计算量、时延、共置成本和带宽占用等因素至关重要。这些资源的有效管理和优化直接关系到系统的高效运行和性能提升。

首先,发热问题需要被高度重视。由于卫星的空间有限,散热能力受到严格限制。高性能计算设备在处理大量遥感数据时会产生显著热量,可能导致设备过热而影响其正常运作和寿命。因此,设计合理的热量控制算法是必要的,以确保卫星内部温度维持在合理范围内。其次,计算量直接影响到选择合适的计算硬件。遥感任务通常涉及复杂的数据处理,如高分辨率图像分析、目标识别等,这些任务需要强大的计算能力来快速完成。因此,需综合考虑其功耗和散热需求,以平衡性能与资源消耗。再者,时延在遥感应用中至关重要,尤其是实时监测任务。数据从传感器传输到处理单元再到输出结果所花费的时间直接影响系统的响应速度。共置成本也是一个需要综合考虑的因素。过多的计算任务同时交由同一卫星上的板卡计算(即计算任务的共置)时,会由于计算资源的分配导致任务的完成被大大拖延。因此,在配置这些资源时,必须进行权衡,选择既能满足性能需求又不会超出卫星负载限制且任务完成效率较高的方案。最后,带宽占用直接影响

数据传输的效率。遥感任务会产生大量数据，需要通过有限的通信链路传送到地面或与其他卫星共享。

综上所述，在考虑遥感大小模型协同工作与调度时，必须全面考虑发热、计算量、时延、共置成本和带宽占用等因素，并通过合理的算法设计和合理调度，实现高效的数据处理和实时响应，从而满足遥感应用的需求。

1.4.2 必要性分析

专门针对卫星在轨计算的成本量化模型目前比较缺乏。对于卫星在轨计算的各种成本中，学界当前较为关心的是时延，即地面端向卫星发送请求后，卫星(或卫星计算集群)向地面端返回结果的间隔时长。对于其他方面的成本控制研究较少，例如计算任务的能耗、发热、多个计算任务共置于同一颗卫星上时造成的计算缓慢等。对于处于太空环境的卫星而言，由于体积、发热、算力方面均有限制，所以我们在进行任务调度时必须考虑卫星的成本红线^[24]。因此，当前卫星边缘计算领域缺乏一个能够将限制卫星计算能力的各种成本进行量化、统一考虑并统筹规划的数学模型。这个量化模型可以帮助星地之间、星星之间的任务调度、卸载更加合理，从而高效、快速的完成计算任务的同时尽可能延长卫星的使用寿命，节约成本。

1.5 技术问题

卫星在轨计算的成本有很多种，且其互相之间存在制约关系。例如如果想要使得卫星计算过程中的发热减少或是降低卫星计算板卡的功耗，那么星上任务处理的时间势必会增加，意味着地面端得到任务处理结果的时延会变长；又或者处理某个既可以在卫星上完成计算，也可以将数据传回地面完成计算的任务时，在星上计算导致的发热、能耗等成本与将数据传回地面导致的时延、发热等成本之间的平衡。因此，如何在卫星在轨计算的成本间合理地进行平衡并选出最优化方案是一个技术难点。

卫星在轨计算的各种成本难以精确量化。首先是学界当前对于在轨计算的成本建模缺乏普遍性的共识，也缺乏对其规律的探究和讨论以及建模。其次是涉及到多方面、多学科的专业知识。例如确定卫星板卡在进行某一计算任务时的散热、

功耗需要微电子、材料学相关知识；确定星地间通讯的时延成本需要通信工程专业相关知识；如要对卫星板卡同时处理多任务造成的额外时延(即共置成本)进行建模则需要计算机专业相关的知识，且这些成本的量化模型在对应学科当前不一定存在精确的建模。

卫星在轨计算的各种成本的单位并不统一，例如时延的单位是毫秒(ms)、发热的单位是焦耳(J)、浮点运算频率的单位是每秒十亿次浮点运算(GFLOPS)、卫星上下行带宽的单位是每秒传输的字节数(Bps)，因此在对成本进行建模的时候需要对不同的成本的数字分别与另一个系数(无量纲系数)作积，将积作为这项成本对卫星在轨计算的“影响”。类同于对卫星在轨计算的过程中的各种成本进行“归一化”，使得其更方便用于卫星成本的量化建模。

1.6 主要研究内容

本论文面向卫星在轨计算任务在地面遥感大模型与星上遥感小模型之间的调度问题，针对不同的调度方式对卫星上各类与卫星计算相关的资源造成的损耗，也即成本，提出了量化的数学模型。并针对提出的量化成本数学模型，采用强化学习算法对其进行求解，以获得成本最小化的调度策略。本研究重点突破了卫星在地面大模型与星上小模型间调度计算任务的问题，为卫星上宝贵计算资源的利用与成本控制提供了新的思路与可行方案。

本文的主要研究内容概括如下：

1、构建了一个卫星计算任务处理的成本评估框架。该框架全面考虑了设备发热量、处理延迟、能源消耗以及任务并行运行的开销等关键支出因素。通过这一方法，可以对不同类型的任务进行成本量化分析，从而科学地决定其最优部署位置(地面或卫星)。

2、设计了一种基于强化学习中 DQN 算法的任务分配机制。本研究通过整合第一部分的成本评估体系来构建激励函数，将不同的任务分配方案设为决策选项，并以各项任务的具体能耗、时延等参数作为状态空间进行神经网络训练。这样可以在接收到新任务请求时，快速识别出最优的执行策略。

3、对 DQN 算法进行改进，提出了 DQN-RSF 算法，提出了 epsilon 重置、选择性的更新网络参数以及经验回放缓存重置机制，相较于 DQN 算法极大的提

升了所训练模型的准确率，并展现了对其它强化学习领域问题的应用潜力。

2 卫星计算任务处理的量化成本数学建模

2.1 动机与研究思路

随着卫星系统的快速发展,尤其是多颗卫星协同工作以及高分辨率遥感数据的广泛应用,卫星计算任务的复杂性和规模不断扩大。然而,由于卫星资源(如计算能力、通信带宽、能源供应等)的有限性,如何高效地分配和调度这些资源以满足多样化的任务需求成为了一个关键挑战。在这种背景下,量化成本建模的动机在于为卫星计算任务提供一个精确的成本评估工具,从而优化资源分配、提升系统效率,并支持科学决策。

表 2.1 量化成本建模中各项成本及其被考量的原因

	原因
任务处理发热	由于卫星特殊的运行环境,其工作发热应当受到严格限制与保护,以确保其正常工作。
任务运算量	卫星上算力相较地面较为缺乏,因此在调度过程中需要对其进行限制,以将算力强需求的任务调度至地面完成。
任务处理及传输时延	由于部分遥感任务的实时性,其对于任务处理以及传输的时延要求严格。
任务处理共置成本	由于卫星同时可能处理一至多个计算任务,而多计算任务共置于同一卫星上会导致计算任务处理效率下降。
数据及结果传输占用带宽	卫星与地面间的上下行带宽非常宝贵,因此需要对其使用进行限制。

研究首先明确量化成本建模的目标,例如:如何衡量卫星计算任务的资源消耗(如计算时间、能源使用、通信延迟等)、如何评估不同任务对系统资源的需求差异、以及如何通过模型支持动态的任务调度和资源分配。同时,需结合实际应用场景分析问题的关键影响因素。

本章将根据不同类型的遥感任务在卫星上计算的相关参数,尽可能贴合实际情况地构建起卫星计算的数学模型。主要考虑发热、任务所需浮点运算次数、时

延、共置成本和占用带宽等因素，对卫星任务调度的动作空间中不同类型的决策分别进行建模，并最终构建起卫星计算任务处理的量化成本数学建模，具体考虑的因素见表2.1。

2.2 本文中大小模型的定义

本文中所提到的遥感大模型指部署在地面上的、参数量巨大、对算力要求较高、运行发热较为严重、计算量较大的模型。其任务处理的效率很高、所需时间极短。由于卫星计算的场景较为特殊，相对于卫星，地面拥有着近乎无限的算力与发热限制、带宽等资源，而本研究主要关注卫星计算中星载资源的消耗，所以本文在对部署在地面的大模型的计算成本建模时并未考虑时延、发热等成本。

本文中所提到的遥感小模型指部署在卫星板卡上的、参数量较小、对算力要求较小、运行发热较少、所需计算量较小的模型。它们任务处理的时间较长、效率较低。

由于大小模型自身的特性，在任务调度时，我们需要充分考虑大模型和小模型自身的优劣，在计算任务处理效率与发热、计算量等成本之间寻找平衡，使得卫星能够在有限的资源限制下尽可能高效、准确地完成计算任务。

2.3 数学模型构建

2.3.1 发热成本因素分析

发热对卫星在轨计算的影响是多方面的。首先，过高的温度可能导致电子元件的物理损坏，如芯片的老化或失效，以及连接器和焊点的受损。其次，高温会降低处理器和其他高性能芯片的工作效率，导致计算速度减慢，影响数据处理能力和任务响应时间^[25]。此外，高温可能引发存储介质的数据错误或逻辑电路的行为异常，从而影响数据的完整性和准确性。长期的热量积累还会缩短电子元件的寿命，增加系统故障的风险和维护成本^[26]。为了应对高温，卫星需要额外的电力用于冷却系统，这会增加能源消耗，影响电池寿命，并限制可用能量以支持其他关键任务。此外，高温可能导致电磁噪声增加，干扰卫星的通信系统，影响数据传输的可靠性和完整性。最后，在设计阶段，必须预留足够的空间和资源用于散

热系统，这可能限制了其他组件的安装或增加了整体重量。维护过热问题通常需要复杂的解决方案，如硬件更换和软件调整，这对在轨维护来说几乎是不可能的。

因此我们需要将发热考虑进我们的成本建模中，这样可以有效的使得在任务调度过程中将在星上计算高发热的任务合理的传输至地面计算。

具体的公式表示如下：

$$\begin{cases} C_1 = \rho * \omega * \tan(\frac{\pi}{2} * \frac{Q}{Q_{MAX}}) & (Q \geq Q_{MAX}) \\ C_2 = +\infty & (Q \geq Q_{MAX}) \end{cases} \quad (2.1)$$

其中 C_1 指总成本(Cost)中发热这一部分成本； ρ 是一个无量纲系数，由于我们的总成本中包含了各种不同单位的物理量，因此需要一个无量纲系数与各种成本相乘来将不同种类成本的单位统一； ω 是权重，指的是发热量这个物理量在各种成本中的影响比重，如果 ω 较高说明在建模中其所对应的物理量就会被视为影响更大的物理量，从而在最终的调度策略中对发热更少的调度方案予以倾斜； Q 是在执行计算任务时的发热，单位为焦耳(J)； Q_{MAX} 指卫星运行过程中的发热红线^[16]；由于卫星运行中的发热需要严格控制在“红线以下”，我们希望过量发热的行为在我们的模型中得到惩罚，并且惩罚力度随着发热占允许发热总量的比例上升而上升，在占用比例达到百分之百时成本为无穷。因此采用正切函数来描述成本关系， C_1 在 $\frac{Q}{Q_{MAX}}$ 为1时为正无穷，满足对建模中控制发热成本的考虑。

2.3.2 计算量成本因素分析

如果卫星在轨计算中的计算任务量过大(例如浮点运算次数过多)，会对卫星的性能和运行产生多方面的负面影响。首先，大量的浮点运算会导致处理器负载急剧增加，这不仅会消耗更多的电力，还会产生更多的热量。过高的温度会使电子元件的工作效率下降，甚至可能导致芯片损坏或寿命缩短。此外，计算任务的过载还会影响系统的响应速度和稳定性，可能造成数据处理延迟或错误，进而影响卫星的任务执行能力。在能源方面，高负载的计算会增加功耗，这对依赖电池供电的卫星来说是一个严峻挑战，可能会限制其他关键功能的运行。最后，如果计算任务无法及时完成，可能会导致系统资源分配不均，甚至引发软件崩溃或其

他故障，进一步威胁卫星的整体可靠性。因此，在设计卫星在轨计算任务时，必须充分考虑计算量与系统能力之间的平衡，以确保任务的高效可靠执行。

因此我们需要将任务的计算量(浮点运算次数)考虑进我们的成本建模中，这样可以有效的使得在任务调度过程中将在星上计算量过大的任务合理的传输至地面计算。

具体的公式表示如下：

$$C_2 = \rho * \omega * FLOPs \quad (2.2)$$

其中 C_2 指总成本中计算量这一部分成本； ρ 、 ω 与公式(2.3.1)中的含义相同； $FLOPs$ 指计算任务所需要的浮点数计算量，单位为百万次浮点运算(MFLOPs)。

2.3.3 时间成本因素分析

在卫星在轨计算中，时间成本(包括任务处理时延和数据传输时延)对系统的性能、效率和可靠性有着深远的影响。

首先，任务处理时延指的是完成特定计算任务所需的时间。这种延迟会对卫星的任务执行能力产生直接影响：过长的任务处理时延会导致资源竞争，可能使多个任务的调度和执行效率下降；此外，任务积压可能会影响任务完成率，甚至出现任务超时或丢弃的情况。地面端希望星上任务处理时延越低越好，因此需要将任务处理时延考虑进我们的成本模型中去。

其次，数据传输时延指的是数据从星上传回地面控制站所需的时间。这种延迟同样会对卫星的在轨计算产生重要影响：对于需要实时处理和反馈的任务(如卫星自主导航或紧急通信)，过长的数据传输时延会导致响应不及时，甚至可能错过最佳处理时机。

卫星调度一个计算任务时，需要决策其是放在星上计算或是将原数据传回地面端计算；如果放在星上计算将避免将原数据传回地面的时延，只需将任务结果传回地面，但星上算力较为贫瘠，可能会具有较大的任务处理时延；而将任务传回地面计算则会将大量数据从卫星传回地面，具有较大传输时延。

这两部分时延在总成本中以公式表示如下：

$$C_3 = \rho * (\omega_1 * t_1 + \omega_2 * t_2) \quad (2.3)$$

其中 C_3 指总成本中时间这一部分成本； ρ 与公式(2.1)中的含义相同； ω_1 、 ω_2 以先后顺序对应任务处理时延的权重和数据传输时延的权重； t_1 、 t_2 以先后顺序分别对应任务处理时延和数据传输时延，单位为ms。

2.3.4 共置成本因素分析

在卫星在轨计算中，共置成本是指当多个任务在同一颗卫星上并行运行时，由于资源竞争、优先级冲突以及系统复杂性增加而导致的单个任务处理效率下降的现象。这种现象对卫星的整体性能和任务成功率有着深远的影响。

在资源有限的情况下，多个任务同时运行会导致计算资源(如处理器时间)、存储资源(如内存或数据存储空间)以及通信带宽等关键资源被分割。例如，当一颗卫星需要同时执行遥感数据处理、通信中继、导航定位等多种任务时，每个任务都需要占用一定的计算和存储资源。然而，卫星的硬件资源通常是固定的，并且受到重量、体积和功耗的严格限制。因此，多个任务的共存会导致每个任务能够获得的资源减少，进而降低其处理效率。

为了应对这些挑战，需要在任务分配时将共置成本考虑进本文的成本量化模型中。

具体的公式表示如下：

$$C_4 = \rho * \omega * f(n) \quad (2.4)$$

其中 C_4 指总成本中时间这一部分成本； ρ 、 ω 与公式(2.1)中的含义相同； $f(n)$ 代表共置成本随卫星同时处理计算任务的个数而增大的函数，其中 $f(n)$ 为共置成本， n 为同时处理的任务数量。

2.3.5 带宽成本因素分析

卫星向地面传输数据的带宽占用成本对在轨计算的影响是多方面的。首先，在轨计算需要处理和传输大量数据，包括遥感图像、通信数据或其他任务生成的信息。然而，卫星与地面之间的通信链路受到频谱资源的严格限制，可用带宽通常有限，导致数据传输速率受限。这种带宽限制直接影响了在轨计算的数据处理

效率，尤其是在需要实时传输或快速响应的任务中，可能因数据积压而降低系统的整体性能。

其次，带宽占用成本还与能源消耗密切相关。卫星的通信设备需要消耗电力来维持数据传输，而卫星的能量主要来自太阳能电池板和储能电池，其容量是有限的。在轨计算任务需要平衡数据处理和传输之间的能量分配，过多的带宽占用可能导致其他关键任务(如导航、遥测等)的能量不足，从而影响卫星的整体运行稳定性。所以，卫星向地面传输数据的带宽占用成本直接影响了数据传输效率、能源消耗以及任务实时性，对在轨计算的整体性能和应用效果具有重要影响。

因此，我们非常有必要将任务调度时可能的卫星向地面传输数据的带宽考虑进我们的成本模型中去。

具体的公式表示如下：

$$\begin{cases} C_5 = \rho * \omega * \tan(\frac{\pi}{2} * \frac{B}{B_{MAX}}) & (B < B_{MAX}) \\ C_5 = +\infty & (B \geq B_{MAX}) \end{cases} \quad (2.5)$$

其中 C_5 指总成本中时间这一部分成本； ρ 、 ω 与公式(2.1)中的含义相同； B 指被调度任务所需数据下行时所占用的带宽，单位为百万位每秒(Mbps)； B_{MAX} 指卫星数据下行的带宽上限。由于卫星数据传输的带宽宝贵，我们希望占用带宽的行为在我们的模型中得到惩罚，并且惩罚力度随着占用带宽的比例上升而上升，在占用比例达到百分之百时成本为无穷。因此采用正切函数来描述成本关系， C_5 在 $\frac{B}{B_{MAX}}$ 为1时为正无穷，满足对建模中控制带宽占用成本的考虑。

2.4 动作空间中的成本建模

针对不同的任务种类及其特性，卫星任务调度的动作空间主要有以下三种：任务在卫星上由遥感小模型处理并将结果返回地面；任务所需数据在卫星上利用遥感小模型分割后(适用目标识别或灾害检测等任务中，图像中有大片无用部分不必传回地面)传回地面交由地面遥感大模型处理；任务直接将所有所需数据传回地面由遥感大模型处理。

本节将针对这三种不同的调度方式分别对其成本进行建模，为下一章应用强化学习的方法进行任务调度提供数学建模的支撑。

2.4.1 卫星侧的成本建模

任务由在卫星上的遥感小模型处理时的成本主要有以下几部分：任务处理时的发热成本、任务计算所需的浮点运算次数成本、任务在星上处理所需的时间成本、处理结果传到地面所需的时延、单星可能同时处理多个任务导致的共置成本(具体解释见2.2.4)、任务处理结果传向地面导致的带宽占用成本。

因此在此情境下的成本用公式表达如下：

$$\begin{aligned} \sum \text{Cost} = & \rho_Q * \omega_Q * \tan\left(\frac{\pi}{2} * \frac{Q}{Q_{MAX}}\right) \\ & + \rho_{FLOPs} * \omega_{FLOPs} * FLOPs \\ & + \rho_t * (\omega_{t1} * t_1 + \omega_{t2} * t_2) + \rho_f * \omega_f * f(n) \\ & + \rho_B * \omega_B * \tan\left(\frac{\pi}{2} * \frac{B}{B_{MAX}}\right) \end{aligned} \quad (2.6)$$

2.4.2 地面侧的成本建模

任务由地面的遥感大模型计算时的成本主要有以下几部分：将数据由卫星传输至地面所造成的发热成本、时延成本和带宽占用成本。由于地面的计算资源相对于卫星可视为无限，且地面的计算成本并非本文的主要关注重点和研究对象，所以此处不再考虑地面计算的发热成本。

因此在此情境下的成本用公式表达如下：

$$\begin{aligned} \sum \text{Cost} = & \rho_Q * \omega_Q * \tan\left(\frac{\pi}{2} * \frac{Q}{Q_{MAX}}\right) + \rho_t * \omega_{t1} * t_1 \\ & + \rho_B * \omega_B * \tan\left(\frac{\pi}{2} * \frac{B}{B_{MAX}}\right) \end{aligned} \quad (2.7)$$

2.4.3 星地双侧协同成本建模

任务由在卫星上的遥感小模型预处理(图像分割)并发回地面大模型计算时的成本主要有以下几部分：任务预处理时的发热成本、任务在星上预处理所需的时间成本、任务预处理所需的浮点运算次数成本、预处理后打包数据传到地面所需的时延、将数据由卫星传输至地面所造成的发热成本和以及带宽占用成本。

因此在此情境下的成本用公式表达如下：

$$\begin{aligned}
\sum \text{Cost} = & \rho_Q * \omega_Q * \tan\left(\frac{\pi}{2} * \frac{Q_{\text{pre}} + Q_{\text{trans}}}{Q_{\text{MAX}}}\right) \\
& + \rho_t * (\omega_{t_{\text{pre}}} * t_{\text{pre}} + \omega_{t_{\text{trans}}} * t_{\text{trans}}) \\
& + \rho_{\text{FLOPs}} * \omega_{\text{FLOPs}} * \text{FLOPs} \\
& + \rho_B * \omega_B * \tan\left(\frac{\pi}{2} * \frac{B}{B_{\text{MAX}}}\right)
\end{aligned} \tag{2.8}$$

2.5 本章小结

本章围绕卫星计算任务处理的量化成本数学建模展开，重点研究了如何通过量化成本建模优化卫星资源的分配与调度，以应对卫星系统快速发展带来的复杂性和资源有限性挑战。随着多卫星协同工作和高分辨率遥感数据的广泛应用，卫星计算任务的复杂性和规模不断扩大，而卫星资源(如计算能力、通信带宽、能源供应等)有限，如何高效分配和调度这些资源成为关键挑战。量化成本建模的目标是为卫星计算任务提供精确的成本评估工具，从而优化资源分配、提升系统效率，并支持科学决策。

在建模过程中，详细分析了发热成本、计算量成本、时间成本、共置成本和带宽占用成本等关键因素。发热成本建模考虑了卫星在轨计算中因高温导致的电子元件损坏、效率下降、数据错误等问题，并通过正切函数描述发热成本与允许发热量之间的关系。计算量成本建模关注任务所需的浮点运算次数对卫星性能和能源消耗的影响。时间成本建模包括任务处理时延和数据传输时延，分别影响任务执行效率和实时性。共置成本建模分析了多任务并行运行时资源竞争导致的效率下降问题。带宽占用成本建模则考虑了卫星数据传输带宽有限对任务调度的影响。

最后，本章针对三种不同的任务调度方式(任务在卫星上处理、任务在地面处理、任务在卫星上预处理并发回地面处理)分别构建了成本模型，为后续应用强化学习方法进行任务调度提供了数学建模支撑。

3 基于强化学习的任务调度网络设计

3.1 动机与研究思路

由于本研究中的卫星计算调度任务是根据多种成本(发热、时延等)选出总成本最小化的最优策略,其本质是对一个多维状态空间中的状态元组(发热、时延等)选出对应的多维动作空间中的最优动作(调度策略),以最小化这个动作所对应状态元组的成本损耗。根据卫星计算任务调度的任务特性,本研究选取强化学习方法。由于强化学习适用于需要在动态环境中做出决策,并通过奖励机制获得反馈的任务,因此在本研究中具有适用性。

强化学习中有很多具体的算法,例如 DQN(Deep Q-learning)^[27]、DDPG^[28]、TD3^[29]和 PPO^[30]等等,不同的算法有不同的应用场景。由于我们在第二章中的任务成本量化建模中的成本为连续值(例如发热、时延均可以在合理的实数范围内不间断的取值),而调度策略为离散值(我们只能在已有的三种调度策略中选取一种,不存在两种策略的中间值),因此 DQN 为众多强化学习算法中较为适合本研究内容的算法。

本章将根据第二章的卫星计算任务量化成本建模对所使用的 DQN 算法的状态空间、动作空间以及奖励函数进行建模,并介绍所使用的网络结构等相关网络设计。

3.2 理论基础

3.2.1 强化学习

强化学习(Reinforcement Learning, RL)作为机器学习的核心分支之一,其核心目标是通过智能体与环境的动态交互,逐步学习能够最大化长期累积奖励的最优决策策略。与依赖标注数据的监督学习和聚焦无标签数据内在结构的无监督学习不同,强化学习的核心特征在于“试错探索”与“延迟反馈”:智能体在未知环境中主动尝试动作,根据环境返回的即时奖励信号调整策略,最终通过反复迭代实现从经验中自主学习。这一过程模拟了生物通过奖惩机制适应环境的核心逻辑,因此被视为实现通用人工智能的重要路径之一。

强化学习的框架主要由三个核心要素构成：智能体 (Agent)、环境 (Environment) 和奖励 (Reward)。智能体作为决策主体，通过感知环境的状态 (State) 选择动作 (Action)，环境则根据动作更新状态并反馈奖励——这一奖励并非对单步动作的即时评价，而是引导智能体权衡短期收益与长期目标的关键信号。为实现高效学习，强化学习需依赖策略 (Policy) 和值函数 (Value Function) 两大数学工具：策略定义了状态到动作的映射规则 (如确定性或随机性策略)，而值函数则通过预估未来累积奖励，为策略优化提供长期视角。两者的结合使得智能体能够在复杂、动态的环境中平衡探索 (尝试新动作) 与利用 (依赖已知最优动作) 的矛盾。

强化学习的理论根基可追溯至20世纪50年代的动态规划^[31]与最优控制理论，但直到90年代随着时序差分学习 (Temporal Difference Learning)^[32]和Q-learning^[33]等算法的突破，其应用范围才逐渐扩展至机器人控制、游戏AI等领域。近年来，深度学习与强化学习的结合彻底改变了这一领域的技术格局：2016年AlphaGo击败人类围棋冠军的里程碑事件，正是基于深度神经网络对状态空间的高效表征与策略优化能力的结合。

由于强化学习在复杂决策场景上的优秀表现，因此本研究采取强化学习来执行卫星计算任务调度。

3.2.2 深度 Q 网络 (Deep Q-Network, DQN)

深度强化学习 (Deep Reinforcement Learning, Deep RL) 的算法演进中，深度 Q 网络 (Deep Q-Network, DQN) 无疑是具有里程碑意义的突破。DQN 的核心思想是将 Q-learning 的时序差分更新与深度神经网络相结合，利用神经网络逼近高维状态空间下的 Q 值函数。传统 Q-learning 依赖表格存储每个状态-动作对的 Q 值，但在复杂场景中，状态空间维度极高，表格存储与计算变得不可行。DQN 通过深度神经网络直接处理原始输入，输出每个动作对应的 Q 值预测，从而实现对 Q 函数的端到端拟合。然而，直接结合神经网络与 Q-learning 会面临两大挑战：一是神经网络需要大量独立同分布的数据以保证训练稳定，而强化学习的时序关联样本容易导致相关性过强；二是 Q 值目标的动态变化会引发网络更新震荡。为此，DQN 引入了经验回放 (Experience Replay) 和固定目标网络 (Target Network) 两大关键技术：经验回放通过存储智能体的交互轨迹并随机采样历史数

据打破时序相关性，同时提高数据利用率；固定目标网络则通过定期复制主网络参数生成相对稳定的 Q 值目标，缓解目标值波动问题。

对于本研究的任务背景，其状态空间为多维连续值(对应着成本建模中的多种成本)，而动作空间为离散值(对应着可以选择的三种调度策略)，而DQN在连续状态、离散动作的任务类型上相对于其它深度强化学习算法具有良好表现，因此采取DQN算法作为本研究所用强化学习算法。

3.2.3 Epsilon-Greedy 方法

Epsilon-Greedy算法是强化学习中用于平衡探索与利用的一种基础而高效的策略。其核心思想在于，在智能体的决策过程中，以一定的概率(称为 ϵ)随机选择动作以探索环境，而以剩余的概率($1 - \epsilon$)选择当前已知最优的动作以利用已有知识。这种机制通过动态调整探索与利用的比例，帮助智能体在未知环境中逐步优化策略。具体而言，假设智能体在某个状态下有多个可选动作，其中当前Q值最高的动作为最优动作，Epsilon-Greedy会以 $1 - \epsilon$ 的概率选择该最优动作，而以 ϵ 的概率均匀随机选择其他动作。例如，若 ϵ 设为0.1，则智能体在90%的情况下遵循当前最优策略，10%的情况下尝试随机动作以发现潜在更优的选择。

在实际应用中， ϵ 的值通常不会固定不变，而是随着训练过程逐步衰减。例如，在训练初期，智能体对环境的认知有限，此时设置较高的 ϵ (如0.9)以鼓励广泛探索；随着训练的推进， ϵ 逐渐降低(如线性衰减至0.01)，使策略逐步收敛到利用已知的最优动作。这种动态调整机制既保证了初期充分探索状态空间的可能性，又避免了后期因过度随机干扰策略稳定性。然而，Epsilon-Greedy的随机性也可能导致效率问题——在高维动作空间或奖励稀疏的任务中，盲目均匀探索可能需要极长时间才能发现有效动作。为此，研究者常将其与其他技术结合，例如在深度Q网络(DQN)中，经验回放机制通过存储历史交互数据并随机采样，间接缓解了探索效率的不足。此外，一些改进方法尝试根据状态的不确定性或历史信息动态调整 ϵ ，例如优先探索那些未被充分访问的状态区域。尽管如此，Epsilon-Greedy因其直观性和可调性，仍是许多强化学习算法的默认选择。过高的初始 ϵ 可能导致早期策略混乱，而过快的衰减则可能使智能体陷入局部最优。因此，合理设计 ϵ 的初始值及衰减曲线，成为实际应用中调参的关键环节之一。

3.3 网络的状态空间、动作空间和奖励函数设计

在第三章中，我们已经对卫星在计算过程中的各种成本进行了数学建模，写明了各类成本与总成本之间的函数关系(如 2.1、2.2 等公式)。本节将根据第三章的量化成本建模定义我们所使用的 DQN 算法的状态空间、动作空间和奖励函数。

3.3.1 状态空间

表 3.1 状态空间中的各项状态汇总

可采取的调度策略	状态空间中状态
任务由在卫星上的遥感小模型处理对应的状态	Q (发热)
	$FLOPs$ (计算量)
	t_1 (任务处理耗时)
	t_2 (结果传输耗时)
	$f(n)$ (共置成本)
	B (带宽占用)
任务由地面上的遥感大模型处理对应的状态	Q (发热)
	t (结果传输耗时)
	B (带宽占用)
任务由在卫星上的遥感小模型预处理并返回地面大模型计算对应的状态	Q_{pre} (数据预处理发热)
	Q_{trans} (数据传输发热)
	t_{pre} (数据预处理耗时)
	t_{trans} (数据传输耗时)
	$FLOPs$ (计算量)
	B (带宽占用)

状态空间即 DQN 智能体做出决策的依据，在本研究中即为第二章阐述的各类成本(发热、时延等)。由于卫星计算调度任务的三种调度策略中(三种策略详见

2.3)的任意一种的发热、时延等成本均不同，因此需要将不同调度策略的发热、时延等成本区分开来，作为不同的状态。根据 2.2 中的成本因素，我们定义的状态空间中的状态见表 3.1。

状态空间中共计十五个不同的状态，且状态取值不间断。即状态空间为十五维且连续。

3.3.2 动作空间

DQN算法的动作空间即2.3中阐述的三种卫星计算任务调度策略，分别为任务由在卫星上的遥感小模型处理、任务由地面的遥感大模型处理、任务由在卫星上的遥感小模型预处理并发回地面大模型计算。对应着动作空间的三种动作。

3.3.3 奖励函数

DQN算法选择不同动作对应的奖励函数即2.3中成本量化建模的不同动作下的成本的负数。因为我们希望卫星在进行决策时选择成本最小化的那个动作，所以将成本取负作为奖励函数可以满足我们希望成本最小化的要求。即成本越大，奖励越少。

因此将任务由在卫星上的遥感小模型处理的奖励函数定义如下：

$$\begin{aligned} \sum reward_1 = & -\rho_Q * \omega_Q * \tan\left(\frac{\pi}{2} * \frac{Q}{Q_{MAX}}\right) \\ & -\rho_{FLOPs} * \omega_{FLOPs} * FLOPs \\ & -\rho_t * (\omega_{t1} * t_1 + \omega_{t2} * t_2) - \rho_f * \omega_f * f(n) \\ & -\rho_B * \omega_B * \tan\left(\frac{\pi}{2} * \frac{B}{B_{MAX}}\right) \end{aligned} \quad (3.1)$$

将任务由地面的遥感大模型处理的奖励函数定义如下：

$$\begin{aligned} \sum reward_2 = & -\rho_Q * \omega_Q * \tan\left(\frac{\pi}{2} * \frac{Q}{Q_{MAX}}\right) - \rho_t * \omega_{t1} * t_1 \\ & -\rho_B * \omega_B * \tan\left(\frac{\pi}{2} * \frac{B}{B_{MAX}}\right) \end{aligned} \quad (3.2)$$

将任务由在卫星上的遥感小模型预处理并发回地面大模型计算的奖励函数定义如下：

$$\begin{aligned}
\sum reward_3 = & -\rho_Q * \omega_Q * \tan\left(\frac{\pi}{2} * \frac{Q_{pre} + Q_{trans}}{Q_{MAX}}\right) \\
& -\rho_t * (\omega_{t_{pre}} * t_{pre} + \omega_{t_{trans}} * t_{trans}) \\
& -\rho_{FLOPs} * \omega_{FLOPs} * FLOPs \\
& -\rho_B * \omega_B * \tan\left(\frac{\pi}{2} * \frac{B}{B_{MAX}}\right)
\end{aligned} \tag{3.3}$$

这三个奖励函数中变量的含义可以参照第二章中对这些变量的解释。至此，动作空间的三个动作所对应的奖励函数定义完毕。

3.4 网络训练算法设计

根据前文所述本任务的特性(连续的状态空间、离散的动作空间)，本研究选取DQN算法作为卫星计算任务调度神经网络的训练算法。同时为保证在训练的过程中网络能够不陷入局部最优，能够充分的探索所有可选的动作空间且避免过度探索，引入了epsilon-greedy算法(算法解释详见3.2)。在超参数(学习率、训练次数、epsilon初始值)设置合理的情况下，使用DQN以及epsilon-greedy算法给网络准确率带来了很大的提升，详细数据可以参照第5章中的解释。

3.5 神经网络结构设计

由于本研究的状态空间维度较高，因此网络不宜设计的深度过浅、结构过简单，经过对比试验以及重复验证，如图3.1的网络结构效果最好：




图3.1 神经网络结构

在网络结构设计中,考虑到本研究的状态空间为十五维连续取值的变量,在训练时可能需要较深、参数较多的网络,因此设计了如图3.1的较深、参数量较大的网络。

其在全连接层的基础上引入了Dropout层^[34],作用在于通过在训练过程中随机屏蔽一部分神经元的输出(图3.1中被隐藏的神经元),迫使网络依赖于更多的特征,从而减少对某些特定神经元的过度依赖。这有助于防止模型过拟合,提高其泛化能力。

3.6 本章小结

本章根据第二章中提出的卫星计算任务处理的量化成本数学建模,面向卫星计算任务在大小模型间调度的问题,采用强化学习领域的DQN算法进行任务调度。本章主要介绍了使用的训练算法、状态空间和动作空间的定义、奖励函数的构建以及网络结构的设计。

本章考量了众多强化学习算法,考虑到本研究状态空间连续、任务空间离散,因此从中选取最适合本研究场景的DQN算法作为解决卫星计算任务调度问题的算法。由于影响任务调度决策的状态有发热、时延、带宽占用、计算量、共置成本这五个方面,而不同的调度策略所对应的这几项成本的值不同,因此要针对不同调度策略建模这几项成本的状态并组成状态空间。奖励函数即根据量化建模中不同调度策略的成本设计,其中常参的设置见实验章节。网络结构的设计考虑到本研究状态空间为十五维的连续值,因此设计了深度为四层的网络,同时引入了Dropout层,以防止数据的过拟合。

本章所训练网络能够较好的完成卫星计算任务的调度,能够较大程度上节省卫星计算资源。本章所训练网络的详细实验结果请阅读第5章。

4 基于 DQN-RSF 的卫星计算任务调度方法研究

第三章中, 本研究在卫星计算任务调度问题上采用DQN算法获取了较好的实验结果。第四章中本研究将在DQN算法的基础上对其进行改进, 以期获得效果更好的网络。

本章提出了DQN-RSF(DQN with epsilon Reset, Selective update and Flushing replay buffer)方法, 其在原有DQN算法的基础上提出了三个改进点: epsilon重置(epsilon reset)、有选择地更新网络参数(selective update)、清空经验回放缓存(flushing replay buffer)。所提出的DQN-RSF方法相较于传统DQN算法在同一测试集上具有显著的任务调度准确度提升, 能够节省更多卫星上的计算资源, 降低卫星计算的成本。

4.1 动机与研究思路

DQN算法在训练过程中存在一些缺点, 比如样本效率较低, 需要大量的数据和时间来达到稳定的性能; 训练过程可能不够稳定, 容易出现波动或者发散的情况; 此外, 由于使用了目标网络(target network)的结构, 使得整体设计相对复杂, 调参和实现起来也有一定的难度。在处理高维状态空间或非常复杂的环境时, DQN的表现可能会不如其他强化学习方法, 并且在探索与利用的平衡上也存在一些局限性。在对基础DQN网络训练的过程中, 基础DQN模型暴露出了在大范围连续的状态空间上泛化程度不高、精确度不高、容易陷入局部最优以及网络难以收敛的问题。基础DQN网络在大范围连续的状态空间尤其是动作空间的临界(即动作空间中的两个动作选择的选择奖励极其接近)时准确率较低。基础DQN网络容易陷入局部最优(或不收敛), 在训练较多轮次后有较大概率对于状态空间中的任意一组状态值网络给出的动作空间中Q值最高的动作总为其中某一种。

为解决以上基础DQN在训练过程中展现出的问题, 本研究提出了DQN-RSF(DQN with epsilon Reset, Selective update and Flushing replay buffer)方法, 主要针对提高网络泛化程度、提高网络准确率、减小网络训练难度(使网络更容易收敛, 减小网络对于训练episode的敏感程度)等方面对基础DQN算法进行改进, 并在测试集上相较传统DQN算法获得了显著更好的结果。

4.2 DQN-RSF 方法

本研究所提出的DQN-RSF算法主要对网络训练时的训练机制进行改进。主要解决基础DQN模型容易陷入局部最优、精确度不高、在大范围连续的状态空间上泛化程度不高等问题。共提出三个机制上的改进点：**epsilon重置(epsilon reset)**、有选择地更新网络参数(**selective update**)、清空经验回放缓存(**flushing replay buffer**)，实验证明DQN-RSF算法相较于DQN算法具有更高的精确度，网络也更不易陷入局部最优。




图4.1 DQN-RSF算法流程概览(与原经典算法区别用红箭头标识)^①

4.2.1 epsilon 重置(epsilon reset)

在基础DQN算法中，epsilon-greedy策略的训练过程如下：首先，在初始阶段，智能体的 epsilon 值较大(例如 0.9)，这意味着智能体会倾向于进行随机动作探索。随着训练的进行，epsilon 会逐渐降低，最终接近于 0，智能体主要通过选择当前最优的动作来最大化累积奖励。

在每次时间步中，智能体会根据当前状态和 epsilon 的值决定是进行随机探索还是选择当前已知的最佳动作。具体来说，当随机数小于 epsilon 时，智能体会执行随机动作(探索)；否则，它会选择具有最大 Q 值的动作(利用)。然后，智

^① 此图请参照 Algorithm 1 对照理解。

能体会根据环境的反馈更新 Q 表或神经网络中的参数，以改进其对未来状态和动作的评估。

epsilon重置(epsilon reset)的主要思想是在经过一段时间的训练后，网络已经初步学习到状态空间到动作空间的映射时，将epsilon重置为一个较大的值，使得经验回放缓存(replay buffer)中添加更多随机动作(即探索)，以期能够使得网络在连续高维状态空间上具有更强的泛化能力，具体机制参照图4.2。

但epsilon重置会在短时间内引入大量的随机动作，必然会导致网络的训练效果在短期内变差，使得要达到与先前相同效果所需的总训练轮次增多，因而我们引入了有选择地更新网络参数(selective update)这一机制。




图4.2 DQN-RSF算法中epsilon随episode变化的图像(以reset point为100000，epsilon decay为0.9999为例)

4.2.2 有选择地更新网络参数(selective update)

为了避免epsilon重置引入大量的随机动作导致的网络准确率变差，在探索和利用之间寻找平衡，我们引入了有选择地更新网络参数(selective update)这一机制。

对于基础DQN算法，在选取一个batch的数据(简单来说就是状态动作对)并计算loss后，会直接对网络的参数进行反向传播。而对于DQN-RSF算法，当我们重置了epsilon后，由于在经验回放缓存(replay buffer)中引入了大量的随机动作，短

时间内随机选取一个batch的loss会激增。我们不希望loss过大的batch被网络所学习，因为这意味着这一个batch所随机到的很多个状态动作对与网络先前所学习到的状态空间与动作空间的映射关系相差甚远，探索数据占据了这一个batch中的很大一部分数据，会影响网络的准确率。

因此在epsilon重置之后，我们会对每一次反向传播的batch限制其loss大小，只有小于某一个loss值的batch才可以被反向传播。这样可以有效地限制epsilon重置对网络精确度造成的损害，使得网络具有良好的泛化能力的同时，精确度受到保护。具体机制如图4.3。




图4.3 DQN-RSF算法中selective update的机制图示

4.2.3 清空经验回放缓存(flushing replay buffer)

经验回放缓存(replay buffer)是基础DQN算法中的一个关键组件，主要用于存储智能体与环境互动时获得的经验和数据。这些经验包括当前状态、采取的动作、获得的奖励以及下一个状态等信息。通过存储这些经验，DQN能够在训练过程中随机抽取一批过去的数据来更新其神经网络模型，从而减少数据的相关性，提高学习的稳定性和效率，并防止模型过拟合训练数据。简单来说，经验回放缓存帮助智能体更有效地回顾和利用以往的经历，以优化其在复杂环境中的决策策略。

对于DQN-RSF算法，在 ϵ 重置并逐渐降至最低值(一般为0.01)之后，此时网络的泛化能力已经具备，我们选择一个适当的时间对经验回放缓存进行清空。由于里面存在过多的随机探索动作，它们的存在对于网络精确度的提升是负面的，因此我们考虑将它清空。之后的经验回放缓存的装填则按照 ϵ 降至最低时的 ϵ 作为探索概率， $1-\epsilon$ 作为利用已经训练好的网络给出动作预测的概率来装填。这样可以极大程度的减少经验回放缓存中的脏数据，在网络具备足够的泛化能力之后大幅度提升精度，详细图示见图4.4。第5章实验证明，这一机制相对与基础DQN算法具有很大的提升。




图4.4 DQN-RSF算法中flushing replay buffer的图示

4.3 DQN-RSF 实现过程

在4.2节中，我们详细探讨了DQN-RSF算法的改进点，即 ϵ Reset, Selective update and Flushing replay buffer机制。其主要是为了使得网络的训练更易收敛、泛化能力更强，同时提高网络的精确度，具体的算法性能请参照第五章实验内容。在此我们给出DQN-RSF算法的伪代码以供参考，详见Algorithm 1。Algorithm 1请结合4.2节内容理解。

Algorithm 1 DQN-RSF

Initialize replay memory D to capacity N
Initialize action-value net Q
Initialize Q_{target} with parameters of Q
for $episode = 1, M$ **do**
 Initialise sequence $s_1 = \{x_1\}$ and preprocessed sequenced $\phi_1 = \phi(s_1)$
 for $t = 1, T$ **do**
 With probability ϵ select a random action a_t
 otherwise select $a_t = \max_a Q(\phi(s_t), a)$
 Execute action a_t in emulator and observe reward r_t and image x_{t+1}
 Set $s_{t+1} = s_t, a_t, x_{t+1}$ and preprocess $\phi_{t+1} = \phi(s_{t+1})$
 Store transition $(\phi_t, a_t, r_t, \phi_{t+1})$ in D
 Sample random minibatch of transitions $(\phi_j, a_j, r_j, \phi_{j+1})$ from D
 Set $y_j \begin{cases} r_j & \text{for terminal } \phi_{j+1} \\ r_j + \lambda \gamma \max_{a'} Q_{target}(\phi_{j+1}, a') & \text{for non-terminal } \phi_{j+1} \end{cases}$
 if $episode > reset\ point$ and $MSELoss(y_j, Q(\phi_j, a_j)) < x$
 do
 Perform a gradient descent step on $y_j - Q(\phi_j, a_j)$ according to MSELoss
 end for
 if $episode = reset\ point$ **do**
 reset ϵ to 1 and gradually decay to 0.01 for a second time
 if $episode = flush\ point$ **do**
 empty D
 Copy parameters of Q to Q_{target} every certain steps
 end for

4.4 本章小结

本章分析了DQN算法在训练过程中的缺点与不足，并提出了DQN-RSF(DQN with epsilon Reset, Selective update and Flushing replay buffer)方法，该方法在原有DQN算法的基础上进行了三项重要改进：首先，引入了epsilon重置机制，在网络初步学习到状态空间与动作空间的映射关系后，将epsilon值重新设置为较大的值，以增加随机探索的动作数量，从而提升网络在连续高维状态空间上的泛化能力；其次，提出了有选择地更新网络参数的方法，通过限制反向传播过程中batch的loss大小，避免了因大量随机动作引入而导致的网络准确率下降问题；最后，设计了清空经验回放缓存的机制，在网络具备足够泛化能力后清除存储中的低效数据，进一步提升了网络的精确度。这些改进使得DQN-RSF方法相较于传统DQN算法在任务调度准确度上实现了显著提升，同时能够更有效地节省卫星计算资源、降低计算成本，并且使网络更容易收敛，相较于原DQN算法在卫星计算任务的调度上展现出了更优秀的性能。

本章所提出算法在卫星计算任务于大小模型间的调度的实际性能请参照实验章节。

5 实验研究

5.1 实验环境

本实验所有网络均在地面服务器上训练，实物如图5.1所示。服务器配置为：
2×20核Intel Xeon Gold 6133 @ 2.50GHz CPU，4×NVIDIA GeForce RTX 4090 GPU，操作系统为Ubuntu 23.04，编程语言为Python 3.8.20，深度学习框架为PyTorch-2.2.0 +cu121，Anaconda的版本为24.9.2。




图5.1 实验所用服务器实物图

5.2 各类参数设置

5.2.1 量化成本建模中各项无量纲系数以及权重设置

由于量化成本建模中需要提前对其中各项的无量纲系数以及权重进行设置，本研究在此给出实验时采用的参数设置以供参考，具体设置见表5.1。

表 5.1 量化成本建模中各项无量纲系数以及权重设置

		ρ (无量纲系数)	ω (权重)
任务由在卫星上的遥感小模型处理的奖励函数中参数值	Q (发热)	2	0.2
	$FLOPs$ (计算量)	0.002	0.2
	t_1 (任务处理耗时)	0.002	0.1
	t_2 (结果传输耗时)	0.002	0.1
	$f(n)$ (共置成本)	0.02	0.2
	B (带宽占用)	2	0.2
任务由地面上的遥感大模型处理的奖励函数中参数值	Q (发热)	2	1/3
	t (结果传输耗时)	0.0015	1/3
	B (带宽占用)	2	0.2
任务由在卫星上的遥感小模型预处理并发回地面大模型计算的奖励函数中参数值	Q_{pre} (数据预处理发热)	2	0.2
	Q_{trans} (数据传输发热)	2	0.2
	t_{pre} (数据预处理耗时)	0.002	0.2
	t_{trans} (数据传输耗时)	0.002	0.2
	$FLOPs$ (计算量)	0.002	0.2
	B (带宽占用)	2	0.2

以上即为本文实验时量化成本建模中各项无量纲系数以及权重的设置,针对不同偏重的调度策略时可以有倾向的提高某部分成本的权重以使得其在调度时被更多的考量,表5.1仅为本文实验时使用的参数设置,仅供参考。

5.2.2 共置成本函数设置

在前文中共置成本使用 $f(n)$ 指代,在实验中,实际使用的 $f(n)$ 函数关系为:

$$f(n) = n^2 \quad (5.1)$$

即共置成本与任务在同一卫星板卡上共置数(n)为平方关系。

5.3 训练数据以及测试集的生成

5.3.1 训练数据的生成

表 5.2 训练网络时训练集状态空间的随机取值范围

		随机取值范围 (单位为参数本身单位)
任务由在卫星上的遥感小型处理的参数值	Q (发热)	(0,1000)
	$FLOPs$ (计算量)	(0,1000)
	t_1 (任务处理耗时)	(0,1000)
	t_2 (结果传输耗时)	(200,300)
	n (共置数)	(0,50)
	B (带宽占用)	(0,1000)
任务由地面上的遥感大模型处理的参数值	Q (发热)	(0,1000)
	t (结果传输耗时)	(200,20000)
	B (带宽占用)	(0,1000)
任务由在卫星上的遥感小型预处理并发回地面大模型	Q_{pre} (数据预处理发热)	(0,1000)
	Q_{trans} (数据传输发热)	(0,1000)
	t_{pre} (数据预处理耗时)	(0,1000)
	t_{trans} (数据传输耗时)	(0,1000)

		随机取值范围（单位为参数本身单位）
计算的参数值	$FLOPs$ (计算量)	(200,20000)
	B (带宽占用)	(0,1000)

由于本研究采用强化学习算法，所以无需标注好的数据，只需在状态空间上成批生成用于训练的数据即可。因此本研究在网络训练阶段的数据采取在合理范围内随机生成的方式产生。

具体产生的方式见表5.2。

5.3.2 测试数据的生成

测试集的生成类似于训练数据的生成，只不过在生成时对变量的取值范围进行了更加严格的限定，以使得所生成的数据取值更符合实际情况，并确保其对不同的调度策略具有状态空间取值上较广的覆盖。这样可以保证测试集可以精确的反映网络的真实性能。

本研究所使用的测试数据总量为30000条，在三种调度策略(按2.4中的先后顺序)上的占比约为4:3:3。测试集对状态空间中的取值具有良好的覆盖。具体的测试数据可见项目源文件。

5.4 实验结果分析

5.4.1 DQN 算法准确度分析

本节中DQN算法所训练网络的结构如3.5中所示。经过对超参数大范围的尝试(超参挑选过程由于过于繁琐在此不多赘述)，挑选效果最好的一组超参，最终确定训练时所使用的参数设置如下： ϵ_decay 为0.9999；学习率为 $1e-4$ ； ϵ 初值为0.7； γ 为0.9；episode为150000至500000内间断取值；replay buffer size为1000000最大长度的deque；batch size为256。

图5.2模型准确率是在5.3.2中提到的自建数据集中测试得到的。

由图5.2看出，基础DQN算法在上述超参设置下，episode在190000至230000之间时网络的准确率最高；episode在150000至210000之间时网络的准确率在逐渐上升，210000次后准确率开始波动。最好一次训练在测试集上的准确率为88.7%。




图5.2 DQN算法所训练网络的准确率随episode的变化趋势

5.4.2 DQN-RSF 算法准确度分析

本节中DQN-RSF算法所训练网络的结构如3.5中所示。同样经过对超参的大范围尝试，挑选效果最好的一组超参，最终确定训练时所使用的参数设置如下：epsilon初值为1；epsilon_decay为0.9999；学习率为 $1e-4$ ；gamma为0.9；episode为350000至600000内间断取值；replay buffer size为1000000最大长度的deque；batch size为256；loss maximum为15；reset point为100000、flush point为200000。

图5.3中的模型准确率是在5.3.2中提到的自建数据集中测试得到的。

由图5.3以看出，DQN-RSF算法在上述超参设置下，episode在350000至500000之间时网络的准确率波动不大，可以认为DQN-RSF对训练轮次不太敏感，比较容易收敛。最好一次训练在测试集上的准确率为95.3%。




图5.3 DQN-RSF算法所训练网络的准确率随episode的变化趋势

5.4.3 准确度对比分析

由图5.4可以看出，DQN-RSF所训练的模型在准确率上明显优于DQN算法所训练的模型。DQN-RSF的图像是从第350000个episode开始的原因，是DQN-RSF的flush point在实验中设置为200000，在replay buffer清空并重新填入数据后，模型还需要经过一段时间对新的replay buffer的训练，从而获得更好的效果。因此，DQN-RSF算法的训练过程相较于DQN算法会更长一些，耗时也会相对更多一些，但是其精确率远高于普通的DQN算法，如图5.4所示。

DQN-RSF算法对训练的episode也并未展现出如普通DQN算法的敏感。对于350000至600000次的训练，其在准确率上表现出较好稳定性，相对而言DQN-RSF算法应用到训练过程中时更易使得网络展现出更好的性能，对于超参数的选择并不非常苛刻。




图5.4 DQN-RSF与DQN算法的准确率随episode变化图像

5.4.4 节省成本的对比分析

本研究在对比两个算法所节省成本时，选择DQN与DQN-RSF算法各自准确率最高的模型，在测试集的30000条数据上分别计算各项成本(星上发热、耗时、星地间带宽占用、星上计算量)的平均值并进行对比。

对比结果见表5.1以及图5.5。

表 5.1 不同的调度方式所产生的平均成本

	Q/J	t/ms	FLOPs/ MFLOPs	B/Mbps
DQN	587.257	2196.378	496.877	398.586
DQN-RSF	539.712	2679.510	419.392	338.674
Large Model	570.540	11442.742	0	616.702
Small Model	791.493	1041.580	791.480	572.935




图5.5 不同调度算法在各项成本指标上的表现

表5.1中的Large Model与Small Model指不使用强化学习的调度算法，而将所有任务不经评估的直接分配给地面的大模型或星上小模型来计算的调度方式。

在图5.5中，将任务全部交由地面大模型来完成的FLOPs成本为0的原因是，此时星上不承担任何计算任务，只需要将任务所需全部数据传回地面即可(而这部分计算量并非研究重点关注的对象，因此合理忽略)。由于不加任何处理地将所有任务源数据传回地面，这也导致了将任务全部交由地面大模型来完成的调度方式在时间成本上显著高于其它几种调度方式。

通过观察图表我们不难发现，除过上一段中提到的特殊情况，强化学习算法的应用在不同的成本指标上相对于直接将任务交给地面大模型或星上小模型的调度方式均有显著提升。且DQN-RSF相对于DQN在除时间消耗外的各个成本指标上均有提升。

5.5 本章小结

通过对基础DQN算法与DQN-RSF算法在具有30000条测试数据的测试集上进行测试，并计算并统计其所减少的成本消耗，我们可以得到如下结论：本文设计的基于强化学习中DQN算法的卫星计算任务调度算法可以大幅度的减少卫星计算资源的消耗，优化卫星计算任务的放置，在任务完成效率与成本间取得平衡。

同时，本文所提出的DQN-RSF算法优化了DQN算法的训练过程，在本文中的卫星计算任务调度的场景中展现了比DQN算法更优秀的性能，同时也展现出在其它强化学习任务中的应用潜力。

6 结论

本研究提出了一套针对卫星计算特点构建的多维度成本评估模型，重点考量了包括发热、时延、功耗以及任务共置在内的关键成本因素。该模型的设计为量化分析不同类型任务在卫星计算环境中的运行成本提供了有效工具，并为优化任务分配策略、合理决策将任务分流至地面节点或卫星系统奠定了基础。

在已提出量化成本建模的基础上，本研究设计了一种基于强化学习中DQN算法的在地面遥感大模型与星上遥感小模型之间调度的算法，并在其基础上进行了改进，提出了DQN-RSF算法。DQN-RSF算法在本调度任务上表现出了比DQN算法更好的性能，为卫星计算任务在地面遥感大模型与星上遥感小模型之间的调度提供了一种可行的方式。

实验结果表明，本文所设计的基于强化学习中DQN算法的任务在地面遥感大模型与星上遥感小模型之间调度的方式相较于任务直接放在地面大模型或星上小模型计算的方式可以将对星上计算成本的消耗削减至原来的二分之一至四分之一。

本文所提出的DQN-RSF算法在DQN算法的基础上进一步优化模型训练过程，在自建验证集上的准确率提高了近10%，可以更好的执行计算任务在地面大模型和星上小模型之间的调度，节省星上的计算资源与各类成本。同时本文所提出的DQN-RSF算法在其它的强化学习问题中也具有可被利用与借鉴的潜力。

参考文献

- [1] 向尚, 陈盈果, 李国梁, et al. 卫星自主与协同任务调度规划综述 [J]. 自动化学报, 2019, 45(2): 252-64.
- [2] 胡泽民, 徐乐园, 黄东瑞, et al. 深度学习在遥感图像处理中的应用综述 [J]. 中国科技期刊数据库 工业 A, 2023, (02): 013-7.
- [3] REDMON J, DIVVALA S, GIRSHICK R, et al. You only look once: Unified, real-time object detection; proceedings of the Proceedings of the IEEE conference on computer vision and pattern recognition, F, 2016 [C].
- [4] GIRSHICK R. Fast r-cnn; proceedings of the Proceedings of the IEEE international conference on computer vision, F, 2015 [C].
- [5] WARD C M, HARGUESS J, CRABB B, et al. Image quality assessment for determining efficacy and limitations of Super-Resolution Convolutional Neural Network (SRCNN); proceedings of the Applications of Digital Image Processing XL, F, 2017 [C]. SPIE.
- [6] WANG X, YU K, WU S, et al. Esrgan: Enhanced super-resolution generative adversarial networks; proceedings of the Proceedings of the European conference on computer vision (ECCV) workshops, F, 2018 [C].
- [7] SALIMANS T, GOODFELLOW I, ZAREMBA W, et al. Improved techniques for training gans [J]. Advances in neural information processing systems, 2016, 29.
- [8] KARRAS T, LAINE S, AITTALA M, et al. Analyzing and improving the image quality of stylegan; proceedings of the Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, F, 2020 [C].
- [9] ZHANG X, ZHANG T, WANG G, et al. Remote sensing object detection meets deep learning: A metareview of challenges and advances [J]. IEEE Geoscience and Remote Sensing Magazine, 2023, 11(4): 8-

44.

- [10] WANG S, LI Q. Satellite computing: Vision and challenges [J]. IEEE Internet of Things Journal, 2023, 10(24): 22514–29.
- [11] 孙云鹤, 王煜, 赵亮, et al. 基于数字孪生的卫星网络移动边缘计算研究综述 [J]. 计算机科学, 2024, 51(12): 12–9.
- [12] Kaelbling L P, Littman M L, Moore A W. Reinforcement learning: A survey [J]. Journal of artificial intelligence research, 1996, 4: 237–85.
- [13] WU J, CHEN Y, HE Y, et al. Survey on autonomous task scheduling technology for Earth observation satellites [J]. Journal of Systems Engineering and Electronics, 2022, 33(6): 1176–89.
- [14] CASALICCHIO E, MAGLIARISI D. Decentralized Task Scheduling in Satellite Edge Computing; proceedings of the 2024 9th International Conference on Fog and Mobile Edge Computing (FMEC), F, 2024 [C]. IEEE.
- [15] MOLCHANOV P, TYREE S, KARRAS T, et al. Pruning convolutional neural networks for resource efficient inference [J]. arXiv preprint arXiv:161106440, 2016.
- [16] KIM J, AHN J, CHOI H-L, et al. Task scheduling of agile satellites with transition time and stereoscopic imaging constraints [J]. Journal of Aerospace Information Systems, 2020, 17(6): 285–93.
- [17] SHEN X, LU Z, LI L, et al. Multi-strip stitching imaging mission planning method for SAR satellites regional mapping considering on-board energy consumption [J]. IEEE Transactions on Geoscience and Remote Sensing, 2024.
- [18] YAO W, SHEN X, ZHANG G, et al. A spiking neural network based proximal policy optimization method for multi-point imaging mission scheduling of earth observation satellite [J]. Swarm and Evolutionary Computation, 2025, 94: 101867.

- [19] QIU Y, NIU J, ZHU X, et al. Mobile edge computing in space-air-ground integrated networks: Architectures, key technologies and challenges [J]. Journal of Sensor and Actuator Networks, 2022, 11(4): 57.
- [20] LIU W, LAI Z, WU Q, et al. In-Orbit Processing or Not? Sunlight-Aware Task Scheduling for Energy-Efficient Space Edge Computing Networks; proceedings of the IEEE INFOCOM 2024-IEEE Conference on Computer Communications, F, 2024 [C]. IEEE.
- [21] CHEN J, HAN P, ZHANG Y, et al. Scheduling energy consumption-constrained workflows in heterogeneous multi-processor embedded systems [J]. Journal of Systems Architecture, 2023, 142: 102938.
- [22] JIANG Q, WANG H, KONG Q, et al. On-orbit remote sensing image processing complex task scheduling model based on heterogeneous multiprocessor [J]. IEEE Transactions on Geoscience and Remote Sensing, 2023, 61: 1-18.
- [23] JIANG Q, ZHENG L, ZHOU Y, et al. Efficient On-Orbit Remote Sensing Imagery Processing via Satellite Edge Computing Resource Scheduling Optimization [J]. IEEE Transactions on Geoscience and Remote Sensing, 2025.
- [24] 虞志刚, 冯旭, 戴天, et al. 空间边缘计算: 需求, 架构及关键技术 [J]. 电子与信息学报, 2022, 44(12): 4416-25.
- [25] ELBULUK M, HAMMOUD A, PATTERSON R. Power electronic components, circuits and systems for deep space missions; proceedings of the 2005 IEEE 36th Power Electronics Specialists Conference, F, 2005 [C]. IEEE.
- [26] 刘佳, 李运泽, 常静, et al. 微小卫星热控系统的研究现状及发展趋势 [J]. 航天器环境工程, 2011, 28(1): 77-82.
- [27] MNIH V, KAVUKCUOGLU K, SILVER D, et al. Playing atari with deep reinforcement learning [J]. arXiv preprint arXiv:13125602, 2013.

- [28] LILLICRAP T P, HUNT J J, PRITZEL A, et al. Continuous control with deep reinforcement learning [J]. arXiv preprint arXiv:1509.02971, 2015.
- [29] FUJIMOTO S, HOOF H, MEGER D. Addressing function approximation error in actor-critic methods; proceedings of the International conference on machine learning, F, 2018 [C]. PMLR.
- [30] SCHULMAN J, WOLSKI F, DHARIWAL P, et al. Proximal policy optimization algorithms [J]. arXiv preprint arXiv:1707.06347, 2017.
- [31] BELLMAN R. Dynamic programming [J]. science, 1966, 153(3731): 34-7.
- [32] TESAURO G. Temporal difference learning and TD-Gammon [J]. Communications of the ACM, 1995, 38(3): 58-68.
- [33] WATKINS C J, DAYAN P. Q-learning [J]. Machine learning, 1992, 8: 279-92.
- [34] SRIVASTAVA N, HINTON G, KRIZHEVSKY A, et al. Dropout: a simple way to prevent neural networks from overfitting [J]. The journal of machine learning research, 2014, 15(1): 1929-58.

致 谢

在珞珈山的四年岁月如梭，如今已至尽头。于此向四年间所有关照过我的人们表示感谢。

感谢我的父母，从你们为人处世的方式中我学到了很多，反思了很多。感谢你们多年来在我的生活与学习上各方面的支持，与我分享大大小小的喜怒哀乐，对你们的情感三言两语难以说得清楚。同样感谢我所有的家人。

感谢李清安老师，李老师在很多方面给予了我很多的帮助，本科期间多次对专业知识甚至人生规划产生疑惑与迷茫时，李老师从他的角度出发给予了我非常具有价值的建议。李老师对我的教诲受用无穷。

感谢陈波老师、刘健老师，在我毕业论文的撰写期间多次与我讨论并给予指导。不论是我手头研究的困扰还是未来的研究方向，你们都能给出最切实的建议。你们是我学术道路上的引路人。

感谢四年间课程的所有任课老师，你们传授的知识丰富了我的智慧。

感谢弘毅班的各位同学，我们合作完成了各种小组作业，参加了各类竞赛，课余时间一起约饭、打球，与你们的交集让我这四年的生活变得有趣。

感谢对本文提出各种意见建议的评审专家与老师们。

感谢武汉大学，感谢珞珈山。在这里度过的四年里的每一个日日夜夜会是我未来的魂牵梦绕。难忘在环山公路上的跑步，东湖栈道的落日，912、信操、桂操的音乐会，教五的桂花香，还有窝在宿舍打的游戏。应该少有机会再体验一次这样的生活了。想要抒情，但又害怕太过分变成矫情，如果没有把握好度的话，还是希望见谅。

上述感谢一定有疏漏，如没有提及，在此补上感谢。

